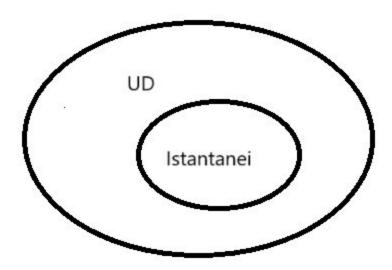


Teoria dell'Informazione

Simone Alessandro Casciaro 22 Ottobre 2024

Lezione 7: Disuguaglianza di Kraft-McMillan

Ripasso



I codici Istantanei sono tutti Univocamente Decodificabili. Tuttavia, ci chiediamo se esiste un codice Univocamente Decodificabile e non Istantaneo che, magari, migliora il valore atteso delle lunghezze.

Il nostro obiettivo è trovare un codice tale che

$$egin{cases} \min_{l_1,\ldots,l_m} \sum_{i=1}^m p_i l_i & \min \mathbb{E}(l_c) \ \sum_{i=1}^m d^{-l_i} \leq 1 & ext{Disuguaglianza di Kraft} \end{cases}$$

Si ricordano le seguenti nozioni:

$$c: \mathbb{X} o D^+ \qquad c ext{ non singolare} \ C_n: \mathbb{X}^n o D^+ \qquad C_n ext{ non singolare} \ C_n(x_1,\ldots,x_n) = c(x_1)\ldots c(x_n) \ l_{C_n}(x_1,\ldots,x_n) = \sum_{i=1}^n l_c(x_i) \qquad n \geq 1 \ l_{max} = \max_{i=1,\ldots,m} l_c(x_i)$$

Teorema di Kraft-McMillan

Siano l_1,\dots,l_m le lunghezze di un codice d-ario Univocamente Decodificabile per una sorgente $<\mathbb{X},\mathbb{P}>$ di m simboli $\iff \sum_{i=1}^m d^{-l_i} \leq 1$

Dimostrazione

Per la disuguaglianza di Kraft, $\sum_{i=1}^m d^{-l_i} \leq 1 \implies \exists c$ istantaneo con lunghezze l_1,\ldots,l_m .

Ma un codice istantaneo è sempre univocamente decodificabile.

$$\Longrightarrow$$

Considero un codice c univocamente decodificabile e calcolo $\left(\sum_{x\in\mathbb{X}}d^{-l_c(x)}
ight)^n$

Se
$$n=2$$

$$\left(\sum_{i=1}^m a_i
ight)^2 = \sum_{i=1}^m a_i * \sum_{j=1}^m a_j = \sum_{i=1}^m \sum_{j=1}^m a_i a_j$$

Nel caso generale,

$$egin{aligned} \left(\sum_{x\in\mathbb{X}}d^{-l_c(x)}
ight)^n &= \sum_{x_1\in\mathbb{X}}\cdots\sum_{x_n\in\mathbb{X}}d^{-l_c(x_1)}\ldots d^{-l_c(x_n)} \ &= \sum_{x_1\in\mathbb{X}}\cdots\sum_{x_n\in\mathbb{X}}d^{-\sum_{i=1}^n l_c(x_i)} \ &= \sum_{(x_1,\ldots,x_n)\in\mathbb{X}^n}d^{-l_{C_n}(x_1,\ldots,x_n)} \end{aligned} \qquad ext{Passiamo alla sorgente } <\mathbb{X}^n,\mathbb{P}_n> \end{aligned}$$

Analizzando l_{C_n} , scopriamo che:

 $n \leq l_{C_n}(x_1,\ldots,x_n)$ perché se ad ogni x_i associo un solo simbolo nella codifica, abbiamo

$$\sum_{i=1}^{n} 1 = n \setminus$$

 $l_{C_n}(x_1,\dots,x_n) \leq n*l_{max}$ perché se ad ogni x_i associo la lunghezza massima della codifica, abbiamo $\sum_n l_{max} = n*l_{max}$

Quindi

$$n \leq l_{C_n}(x_1,\ldots,x_n) \leq n * l_{max}$$

Consideriamo \mathbb{X}^n e lo partizioniamo in k elementi a 2 a 2 disgiunti secondo la lunghezza delle codifiche dato da C_n

Chiamiamo ogni partizione \mathbb{X}^n_k

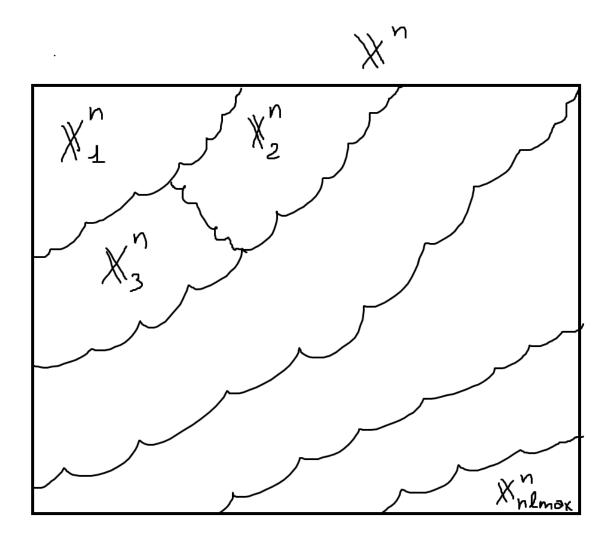
$$\mathbb{X}^n_k=\{(x_1,\ldots,x_n)\in\mathbb{X}^n:l_{C_n}(x_1,\ldots,x_n)=k\}$$

Data la premessa precedente, si ha che se k < n oppure se $k > n * l_{max}$ allora $\mathbb{X}^n_k = \emptyset$ Gli insiemi \mathbb{X}^n_k sono tali che:

•
$$\mathbb{X}_{i}^{n}\cap\mathbb{X}_{j}^{n}=\emptyset$$
 $orall i\neq j$

$$\bullet \bigcap_{l=1}^{n*l_{max}} \mathbb{X}_k^n = \mathbb{X}^n$$

•
$$X_h^n \subset X^n$$



Riprendendo il punto 1, si ha che

$$\left(\sum_{x \in \mathbb{X}} d^{-l_c(x)}\right)^n = \sum_{(x_1, \dots, x_n) \in \mathbb{X}^n} d^{-l_{C_n}(x_1, \dots, x_n)}
= \sum_{k=1}^{nl_{max}} \sum_{(x_1, \dots, x_n) \in \mathbb{X}^n_k} d^{-l_{C_n}(x_1, \dots, x_n)}
= \sum_{k=1}^{nl_{max}} \sum_{(x_1, \dots, x_n) \in \mathbb{X}^n_k} d^{-k}
= \sum_{k=1}^{nl_{max}} |\mathbb{X}^n_k| d^{-k}$$
(1.1)

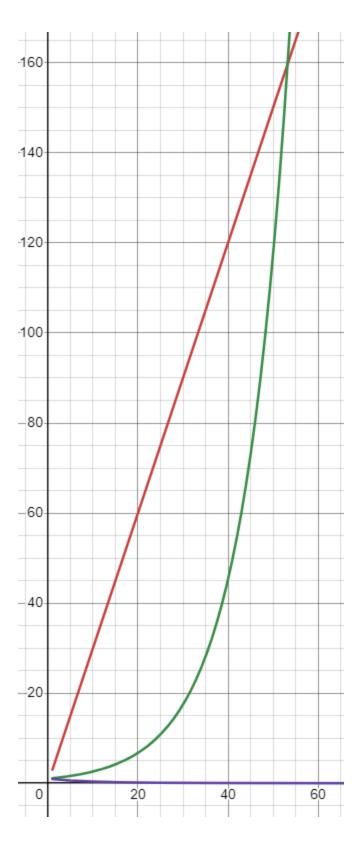
Dato che C_n è una funzione non singolare (e quindi iniettiva), la cardinalità del dominio è minore di quella del codominio. Quindi $|\mathbb{X}^n_k| \leq |D^k|$ Possiamo dunque maggiorare la sommatoria precedente.

$$egin{align} \left(\sum_{x \in \mathbb{X}} d^{-l_c(x)}
ight)^n &= \sum_{k=n}^{nl_{max}} |\mathbb{X}_k^n| d^{-k} \ &\leq \sum_{k=1}^{nl_{max}} |D^k| d^{-k} \ &= \sum_{k=1}^{nl_{max}} d^k d^{-k} \ &= \sum_{k=1}^{nl_{max}} 1 \ &= n * l_{max} \end{cases} \ (1.2)$$

Abbiamo dunque dimostrato che

$$\left(\sum_{x\in\mathbb{X}}d^{-l_c(x)}
ight)^n\leq n*l_{max} \hspace{1cm} (1.2.1)$$

Facendo uno studio di funzione e rinominando $\displaystyle\sum_{x\in\mathbb{X}}d^{-l_c(x)}=M$



notiamo che la disuguaglianza al punto 1.2.1 è rispettata se e solo se $M \leq 1$, quindi abbiamo dimostrato che

$$\sum_{x \in \mathbb{X}} d^{-l_c(x)} \leq 1 \quad \Box$$

Esercizi

1. Data una codifica e 3 possibili spazi di probabilità, trovare il migliore supponendo che vogliamo minimizzare il valore atteso delle lunghezze.

	C_B	p_1	p_2	p_3
x_1	000	0.2	0.4	0.1
x_2	001	0.2	0.2	0.1
x_3	01	0.2	0.2	0.2
x_4	110	0.2	0.1	0.4
x_5	111	0.2	0.1	0.2

Calcolando i 3 valori attesi, si ha che:

$$\mathbb{E}(l_1) = 0.2 * 3 + 0.2 * 3 + 0.2 * 2 + 0.2 * 3 + 0.2 * 3 = 2.8$$

$$\mathbb{E}(l_2) = 0.4 * 3 + 0.2 * 3 + 0.2 * 2 + 0.1 * 3 + 0.1 * 3 = 2.8$$

$$\mathbb{E}(l_3) = 0.1 * 3 + 0.1 * 3 + 0.2 * 2 + 0.4 * 3 + 0.2 * 3 = 2.8$$

Le 3 probabilità sono dunque equivalenti. Tuttavia, per nessuna delle 3 probabilità il codice è ottimale.

2. Data una sorgente
$$\mathbb{X}=\{a_1,\ldots,a_8,a_9,\ldots,a_{12}\}$$
 e $\mathbb{P}(a_i)=$
$$\begin{cases} 0.1 & i=1,\ldots,8\\ 0.05 & i=9,\ldots,12 \end{cases}$$

Dato d=5, trovare un codice istantaneo e, se possibile, ottimale.

Usando l'algoritmo di Huffman, notiamo che il codice restituito non è ottimale, contrariamente a quanto abbiamo studiato nella lezione precedente. Infatti, il codice restituito è il seguente:

$$c(a_1) = 1$$

 $c(a_2) = 2$
 $c(a_3) = 31$

```
c(a_5)=33 c(a_6)=34 c(a_7)=35 c(a_8)=41 c(a_9)=42 c(a_{10})=43 c(a_{11})=44 c(a_{12})=45 Non va bene, perché il sottoalbero del simbolo 5 non viene coperto.
```

Si può risolvere introducendo nell'algoritmo di Huffman un numero di simboli "Dummy" con probabilità 0, per far sì che l'algoritmo possa restituire un codice istantaneo ottimale. Il numero di simboli dummy è dato dalla seguente espressione

$$n+q\equiv 1\mod d-1$$

dove $n=|\mathbb{X}|$ e q è il numero di simboli dummy. Con questi accorgimenti, il codice restituito è:

```
c(a_1) = 1
c(a_2) = 2
c(a_3) = 3
c(a_4) = 41
c(a_5) = 42
c(a_6) = 43
c(a_7) = 44
c(a_8) = 45
c(a_9) = 51
c(a_{10}) = 52
c(a_{11}) = 53
c(a_{12}) = 54
```